iPhone 十段中英混读实测评比与模型选择

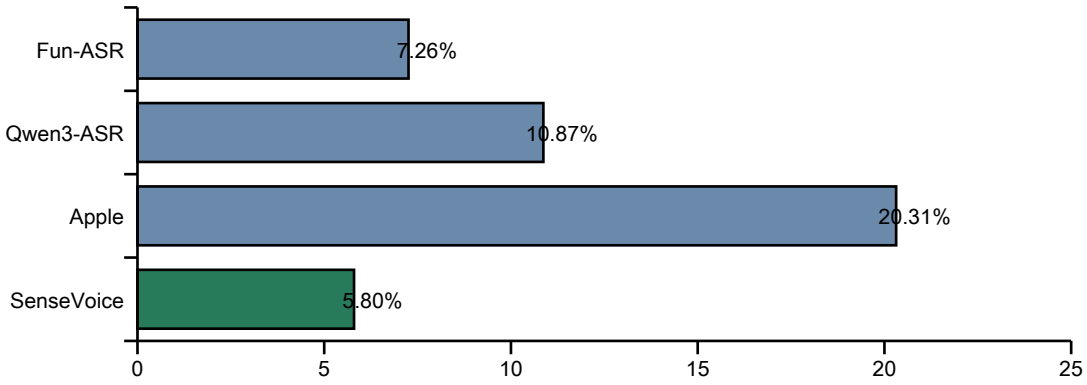
2026-10-29 | 10 条录音 | 599.41 秒 | 4 套本地 ASR

默认推荐：SenseVoiceSmall INT8

默认选择 SenseVoiceSmall INT8：本次 CER 5.80%、英文 WER 5.62%、10/10 完成，平均处理 1.38 秒，含初始化 1.71 秒。它在整体文字保真、英文和速度上最均衡。

模型	完成	总 CER	英文 WER	平均处理 / 秒	含初始化 / 秒
SenseVoice	10/10	5.80%	5.62%	1.38	1.71
Apple Speech	9/10	20.31%	48.19%	2.15	2.42
Qwen3-ASR	10/10	10.87%	20.48%	9.43	10.59
Fun-ASR-MLT-Nano	10/10	7.26%	13.65%	7.95	9.53

总字符错误率 CER（越低越好）



关键结论

SenseVoice 兼顾当前样本的文字保真、英文与低延迟。Fun 可按需复核；Qwen 正常样本表现好，但出现一次长段跨语言改写；Apple 先修语言路由，再评系统识别器。

重要限制：这是对用户提供稿件的一致性评比，未逐字审听原音。数值、否定和专名仍需人工复核；录音 10 中 SenseVoice 把“十先令”写成“1现例”。

主评只取各录音最新 batch 的四模型结果，不混入旧成功记录。失败按空稿计入端到端 CER；Apple 处理时间均值只含 9 条完成记录。

分项、离群值与速度

模型	汉字 CER	MER	中位 CER	数字等值 CER	平均 RTF
SenseVoice	7.68%	7.43%	6.78%	5.52%	0.0230
Apple	17.95%	21.83%	13.34%	19.60%	0.0362
Qwen3-ASR	9.35%	8.93%	5.05%	10.90%	0.1574
Fun-ASR	7.51%	7.48%	5.66%	6.62%	0.1327

每条录音的 CER

录音	SenseVoice	Apple	Qwen3-ASR	Fun-ASR
录音 1	0.84%	1.26%	0.84%	0.84%
录音 2	6.85%	14.11%	5.24%	5.24%
录音 3	3.16%	5.53%	3.16%	1.58%
录音 4	8.23%	18.52%	70.37%	12.35%
录音 5	2.25%	5.99%	0.75%	1.12%
录音 6	8.01%	13.59%	9.41%	8.71%
录音 7	4.58%	失败 / 100%	7.04%	16.20%
录音 8	7.99%	14.58%	4.86%	4.51%
录音 9	8.10%	11.84%	9.03%	13.71%
录音 10	6.71%	13.10%	3.83%	6.07%

浅绿色为该条最低 CER，可能并列。

如何解释分数

Fun 的 MER 7.48%，与 SenseVoice 的 7.43% 接近；Fun 汉字 CER 7.51%，SenseVoice 7.68%。CER 按英文的每个字母计数，主排名对英文更敏感，因此不能只看一个分数。

Qwen 单条中位 CER 为 5.05%，优于 SenseVoice 的 6.78%；但录音 4 的 70.37% 离群值不能隐藏。若仅做诊断、去掉该条，Qwen 其余 9 条 CER 为 5.08%，SenseVoice 为 5.56%。

平均处理时间：SenseVoice 1.38 秒、Apple 2.15 秒（9条）、Qwen 9.43 秒、Fun 7.95 秒。含初始化分别为 1.71、2.42、10.59、9.53 秒。按共同成功的 9 条，SenseVoice / Apple / Qwen / Fun 的 CER 分别为 5.94% / 11.11% / 11.31% / 6.22%。

按录音配对 bootstrap 的 Fun-SenseVoice CER 差值 95%区间为 -1.02 至 +4.34 个百分点，Qwen 为 -1.34 至 +17.10。仅 10 条样本，不宜宣称总体显著领先。

语言路由与纠错：当前瓶颈

Apple 的链路问题

录音 7 的 1.82-3.31 秒标题被 Whisper 判为芬兰语 fi，check_assets 阶段拒绝执行，整条原始转写为空。录音 2 的 42.17-47.31 秒路由为 ja_JP，录音 10 的 45.47-52.14 秒路由为 ko_KR。录音 4、5、8 大段中英交替内容主要使用 zh_CN。

因此 Apple 的端到端 CER 20.31% 评价的是当前语言检测、资源检查和识别组合。即使只看成功的 9 条，CER 仍为 11.11%。不能把误路由造成的失败当成系统模型本体的能力结论。

历史 84 次运行中，SenseVoice 29/29 完成，Apple 21/29 完成、8 次失败，Qwen 16/16 完成，Fun 10/10 完成。历史包含重复重试且次数不均衡，仅供审计，不代表独立随机样本。

实际纠错结果

纠错模型	完成	候选改变	最终改变	均耗时/秒	覆盖录音
Apple 本地	15	13	0	3.33	6 / 7 / 8 / 9
DeepSeek Flash	7	5	0	2.15	7 / 9

22 条最终采用的全文均未变化，已应用 CER 改善为 0。18 条非原样候选全部被拒绝，其余 4 条原样返回；DeepSeek 的 7 条记录覆盖有限，不能作为四套 ASR 的替代排名。

保守检查按整块判断：只要发生修改的整个块包含数字、否定或人物关系等敏感字符，就拒绝整块修改。本次每次基本只有一个较长块，安全的局部修正也会被挡住。

保护也挡住了坏建议：Apple 对录音 9 / SenseVoice 的候选曾把大片英文翻成中文，候选 CER 从 8.10% 恶化到 50.78%。DeepSeek 对录音 7 / SenseVoice 的候选从 4.58% 降为 3.87%，但同样没有应用。候选分数不等于实际采用的效果。

下一步建议

先对纠错使用句级较小块，并只检查实际变化跨度中的敏感事实；保留数值、否定、语言转换和新增事实检查。Apple 路由应处理短片段误判及不支持语言回退。Qwen / Fun 需对跨语言改写做专项回归。本次报告没有修改 App，也没有重新调用模型。

录音 01 | 短中英交替，基础转写

愚公移山：坚持与调整 - - 《列子》

时长 52.63 秒。SenseVoice、Qwen 与 Fun 的总 CER 并列 0.84%；SenseVoice 在三者中最快，且两句英文逐词一致。

模型	CER	英文 WER	处理 / 秒	汉字 CER	数字等值 CER
SenseVoice	0.84%	0.00%	1.14	1.34%	0.84%
Apple	1.26%	0.00%	1.82	2.01%	1.26%
Qwen3-ASR	0.84%	0.00%	7.68	1.34%	0.84%
Fun-ASR	0.84%	4.35%	6.31	0.67%	0.84%

参考原文（标题、正文、出处）

愚公移山：坚持与调整 - - 《列子》
读到愚公移山，我以前觉得老人只是在和困难较劲。现在做项目，才发现真正难的不是第一天拿起工具，而是半年以后，大家还愿不愿意继续。The work may take years, but we still need a plan for tomorrow. 如果一条路走不通，能不能换一种方法？山要不要移，也应该先问问每天经过这里的人。We can change the plan without giving up the goal. 我支持坚持，但不赞成把已经花掉的时间，当成不能停止的理由。今天完成多少，花了多少钱，影响了谁，都要讲清楚。

各模型的关键差异

SenseVoice：“读到”写成“不到”，“不赞成”写成“不赞同”；英文两句完整。

Apple Speech：“真正难的”写成“真正蓝的”，并增加“今天要完成”中的“要”；本条英文路由正确，英文 WER 为 0。

Qwen3-ASR：正文较完整；“不赞成”写成“不赞同”，增加“今天要完成”中的“要”。

Fun-ASR-MLT-Nano：“不赞成”写成“不赞同”；英文“need a plan”漏掉冠词 a，英文 WER 因而高于前两者。

共同偏差 / 复核：“赞成→赞同”四模型共同出现，可能涉及实际朗读差异；本报告仍按提供的原文计分，未擅自改参考稿。

四模型完整原始转写与规范化逐字红绿差异，见配套 HTML 的对应录音章节；完整文字同时保存在 Markdown 报告。

录音 02 | 农具、过去时、否定表达与语序

守株待兔：成功经验是否可靠 - - 《韩非子》

时长 61.48 秒。Qwen 与 Fun 并列最佳，CER 5.24%；Apple 误判一段英文为日语，导致该句严重失真。

模型	CER	英文 WER	处理 / 秒	汉字 CER	数字等值 CER
SenseVoice	6.85%	11.11%	1.35	7.74%	6.05%
Apple	14.11%	44.44%	2.26	7.14%	14.11%
Qwen3-ASR	5.24%	5.56%	9.32	6.55%	5.24%
Fun-ASR	5.24%	5.56%	7.66	6.55%	5.24%

参考原文（标题、正文、出处）

守株待兔：成功经验是否可靠 - - 《韩非子》
宋国有个人捡到撞死在树桩旁的兔子，后来便放下农具，天天等着同样的好事发生。我们笑他的时候，也可以看看自己的工作。Last month, one short video brought us a lot of orders. 于是有人说，以后不用认真做产品，只要每天发视频就行。可上个月有假期，也有价格变化，谁能证明订单只来自视频？One good result does not explain everything. 经验当然值得参考，但如果只记住成功的那一次，却忘了之前十次失败，我们等的可能不是下一只兔子，而是一个碰巧符合期待的答案。

各模型的关键差异

SenseVoice：“农具→龙具”，“brought→bought”；“one short video”写成“The short video”。

Apple Speech：“Last month”写成“Last mouse”；“One good result does not explain everything”出现“Oneコール raseutos not explenthing”。路由记录为 ja_JP，时间 42.17-47.31 秒。

Qwen3-ASR：正确识别“农具”和 brought；仍将 one 写成 The，且保留了多处与脚本不同的语序。

Fun-ASR-MLT-Nano：与 Qwen 的总 CER 相同，英文主体较完整；同样存在 one→The。

共同偏差 / 复核：四模型均出现“当然经验值得参考”“只是来自于视频”等与脚本不同的措辞。它们不能在未审听原音时全部归因于识别错误。

四模型完整原始转写与规范化逐字红绿差异，见配套 HTML 的对应录音章节；完整文字同时保存在 Markdown 报告。

录音 03 | 专名、中文同音字与英文衔接

塞翁失马：判断需要时间 - - 《淮南子》

时长 52.31 秒。Fun 最好，CER 1.58%，英文 WER 为 0；四模型都没有正确写出标题中的“淮南子”。

模型	CER	英文 WER	处理 / 秒	汉字 CER	数字等值 CER
SenseVoice	3.16%	0.00%	1.30	5.03%	3.16%
Apple	5.53%	23.08%	2.06	3.77%	5.53%
Qwen3-ASR	3.16%	0.00%	8.84	5.03%	3.16%
Fun-ASR	1.58%	0.00%	7.63	2.52%	1.58%

参考原文（标题、正文、出处）

塞翁失马：判断需要时间 - - 《淮南子》
塞翁丢了马，邻居觉得这是坏事；后来马回来了，还带来别的马，大家又觉得是好事。小时候读这个故事，我以为什么都不用担心。长大以后才明白，它更像是在提醒我们，不要太早下结论。I did not get the job I wanted, and I felt terrible that night. 可半年以后，我在另一份工作里学到了更多东西。但这也不能证明，当初的失败一定是好事。We can learn from a loss without saying the loss was good. 有些损失确实令人难过，允许自己难过，再决定下一步，或许比急着寻找好处更加诚实。

各模型的关键差异

SenseVoice：“塞翁失马→塞翁诗马”，“淮南子→淮篮子”；英文主体完整。

Apple Speech：“淮南子→怀篮子”；后一句英文被并入 zh_CN 语音区间，出现“cannear”“saings”等错误拼写。

Qwen3-ASR：“淮南子→怀兰子”，首段“塞翁→赛翁”；两句英文逐词一致。

Fun-ASR-MLT-Nano：“淮南子→怀兰子”；其余内容较接近参考，英文两句一致。

共同偏差 / 复核：“急着→着急”和部分“事→事儿”是多模型共同偏差，可能包含口语读法或脚本差异。

四模型完整原始转写与规范化逐字红绿差异，见配套 HTML 的对应录音章节；完整文字同时保存在 Markdown 报告。

录音 04 | fifteen/fifty、中文问句与跨语言改写

曹冲称象：方法与证据 - - 《三国志》

时长 53.33 秒。Qwen 出现本次最严重异常：把一大段中文改写成英文，CER 70.37%。严格 CER 下 SenseVoice 最低，但数字等值处理后 Fun 更好。

模型	CER	英文 WER	处理 / 秒	汉字 CER	数字等值 CER
SenseVoice	8.23%	15.00%	1.36	8.75%	10.64%
Apple	18.52%	60.00%	2.06	13.12%	16.17%
Qwen3-ASR	70.37%	195.00%	9.42	38.75%	72.77%
Fun-ASR	12.35%	20.00%	8.17	8.75%	7.66%

参考原文（标题、正文、出处）

曹冲称象：方法与证据 - - 《三国志》
曹冲称象的故事里，最有意思的不是孩子比大人聪明，而是他换了一个可以实际操作的问题。大象不能直接称，那就先记录船的位置，再用石头比较。We do not have to solve every problem in the same way. 如果把这件事放到今天，我还想多问几句：船上的人有没有变化，水位记得准不准，石头称了几次？第一次是 fifteen，第二次却成了 fifty，就不能直接取一个看起来顺眼的数字。A clever idea needs careful checks. 好方法让我们接近答案，完整记录才能让别人相信答案。

各模型的关键差异

SenseVoice：“fifteen→fift”“fifty→fift0”，数值表达不可靠；“have to solve”写成“have the solve”。

Apple Speech：“曹冲称象→曹聪称相”，英文与数字写成“ft”“5 5”等；整条主要使用 zh_CN。

Qwen3-ASR：参考中的“如果把这件事放到今天……水位记得准不准……”变为“If we put this thing into the present ... The water level is accurate ...”。疑问句变为肯定句，语言和事实表达均偏离；英文 WER 达 195%，不是计算错误，而是大量新增英文。

Fun-ASR-MLT-Nano：将 fifteen/fifty 输出为 15/50，数值本身正确。严格 CER 为 12.35%，数字等值后为 7.66%；仍有“slove”等英文拼写错误。

共同偏差 / 复核：本报告不把 15/50 的格式变化等同于数值错误。四模型共同出现“完整记录才能让人相信，完整记录才能……”的重复，可能是实际自我纠正；未听原音前不将其单独归罪于模型。

四模型完整原始转写与规范化逐字红绿差异，见配套 HTML 的对应录音章节；完整文字同时保存在 Markdown 报告。

录音 05 | 专名、连续中英混读与正文完整性

田忌赛马：整体成绩与个人感受 - - 《史记》

时长 53.67 秒。Qwen 单条最佳，CER 0.75%，两句英文一致；说明它在正常样本上可以优于 SenseVoice。

模型	CER	英文 WER	处理 / 秒	汉字 CER	数字等值 CER
SenseVoice	2.25%	0.00%	1.36	3.59%	2.25%
Apple	5.99%	52.17%	2.06	1.80%	5.99%
Qwen3-ASR	0.75%	0.00%	8.95	1.20%	0.75%
Fun-ASR	1.12%	0.00%	7.46	1.80%	1.12%

参考原文（标题、正文、出处）

田忌赛马：整体成绩与个人感受 - - 《史记》
田忌赛马告诉我们，改变安排，有时比单独提高某一匹马的速度更有效。但如果我是其中一匹马，知道自己被安排去输，心里会怎么想？The team may win, but one person may still feel hurt. 公司分配工作时，也常说这是为了整体利益。问题是，承担最多代价的人，有没有参与讨论，有没有得到合理支持？We should explain the reason before asking people to accept the result. 我并不反对取舍，只是不希望一句顾全大局，就让具体的人失去表达意见的机会。真正好的安排，既要算总账，也要看每个人的处境。

各模型的关键差异

SenseVoice：“史记→实际”“顾全大局→顾权大局”“真正→政正”，有“各每个人”的多字。

Apple Speech：“田忌→田季”，英文出现“teame”“mastil”“except the resurt”等错误；整段路由为 zh_CN。

Qwen3-ASR：主体及英文完整，差异主要是“但只是”“各每个人”等增加的字。

Fun-ASR-MLT-Nano：两句英文一致；“真正好的安排”变为“政治好的安排”，属需要复核的词义变化。

共同偏差 / 复核：“我并不反对取舍，但只是……”是多模型共有的读稿偏差，不宜把所有插入字都解释为幻觉。

四模型完整原始转写与规范化逐字红绿差异，见配套 HTML 的对应录音章节；完整文字同时保存在 Markdown 报告。

录音 06 | 梭伦、英文单词边界与重复

梭伦与国王：财富能否代表幸福 - - 希罗多德《历史》

时长 66.60 秒。SenseVoice CER 最低，8.01%，英文词序列正确；所有模型都受“梭伦”专名和重复片段影响。

模型	CER	英文 WER	处理 / 秒	汉字 CER	数字等值 CER
SenseVoice	8.01%	0.00%	1.38	12.11%	8.01%
Apple	13.59%	36.00%	2.26	12.63%	13.59%
Qwen3-ASR	9.41%	8.00%	9.70	11.58%	9.41%
Fun-ASR	8.71%	28.00%	7.88	12.63%	8.71%

参考原文（标题、正文、出处）

梭伦与国王：财富能否代表幸福 - - 希罗多德《历史》
国王克洛伊索斯展示自己的财富，希望梭伦承认他是最幸福的人，得到的回答却没有满足他的期待。读到这里，我想到同学聚会时，人们总爱先问工资、房子和职位。He has a bigger house, but does he have a better life? 钱能解决许多实际困难，却不能替我们回答所有问题。一个人收入增加了，陪伴家人的时间却减少了，这笔账应该怎么算？We can count the money, but we cannot measure every part of happiness. 梭伦提醒国王留意人生后来的变化，而我更想提醒自己，别用今天看见的成绩，替别人的整个人生打分。
出处：《历史》中的梭伦与克洛伊索斯。

各模型的关键差异

SenseVoice：“梭伦”多次写成“伦梭/轮缩”等，但英文 WER 为 0。

Apple Speech：专名不稳，英文出现“hash”“cont the marley”“happness”等；后半段按 zh_CN 处理。

Qwen3-ASR：“count the money”变为“count them early”，丢失 money 的含义；“梭伦”仍未写对。

Fun-ASR-MLT-Nano：“But does he have a better life”连写成“Butdoeshehaveabetterlife”。按忽略空格的 CER 不计这个边界错误，但严格英文 WER 会计错，实际可读性也受影响。

共同偏差 / 复核：四模型均出现“别用看见今天的成绩，别用今天看得见的成绩……”的自我纠正式重复；原文较简短。该共同偏差会抬高对脚本的 CER。

四模型完整原始转写与规范化逐字红绿差异，见配套 HTML 的对应录音章节；完整文字同时保存在 Markdown 报告。

录音 07 | 罕见专名、错误语言路由与英文被翻译

亚历山大与第欧根尼：帮助是否符合对方需要 - - 普鲁塔克《名人传》

时长 66.15 秒。SenseVoice 最好，CER 4.58%；Apple 整条失败，Fun 将一段英文翻成中文。

模型	CER	英文 WER	处理 / 秒	汉字 CER	数字等值 CER
SenseVoice	4.58%	0.00%	1.41	6.91%	4.58%
Apple	失败 / 100%	100.00%	未完成	100.00%	100.00%
Qwen3-ASR	7.04%	7.14%	9.82	8.51%	7.04%
Fun-ASR	16.20%	32.14%	8.48	14.89%	16.20%

参考原文（标题、正文、出处）

亚历山大与第欧根尼：帮助是否符合对方需要 - - 普鲁塔克《名人传》
亚历山大问第欧根尼需要什么帮助，对方却只希望他让开一点，不要挡住阳光。这个回答让我想到，我们给别人建议时，往往先想到自己能提供什么，却没有认真问对方需要什么。You may offer a better job, but he may need more time with his family. 朋友想休息，我却替他安排学习；父母想聊天，我却给他们买了一部新手机。礼物越来越贵，交流却越来越少。Before I say “let me help,” I should ask “what do you need?” 有时真正有用的帮助，不是增加一个选择，而是少一点打扰，把决定生活的权利留给对方。
出处：《亚历山大传》第十四节。

各模型的关键差异

SenseVoice：英文词序列与原文一致；“第欧根尼”出现“迪欧跟尼”等专名错误，标题“与”也出现同音误识。

Apple Speech：Whisper 将 1.82-3.31 秒的标题片段判为 fi（芬兰语），在 check_assets 阶段被拒绝，原始转写为空。失败归属于当前 Demo 的语言检测 / 路由链路，不等于已经证明系统识别器本体不能识别这段中文。

Qwen3-ASR：“You may offer a better job”变为“You may have a better job”，并出现“Do跟你”等混合字形。

Fun-ASR-MLT-Nano：“But he may need more time with his family”被改为“但，他可能需要更多时间与他的家人”，不满足逐字保留原语言的转写要求。

共同偏差 / 复核：按用户原文标题和出处全部计分。Apple 失败按空稿计入端到端总分；报告另给成功样本分数，避免隐藏失败。

四模型完整原始转写与规范化逐字红绿差异，见配套 HTML 的对应录音章节；完整文字同时保存在 Markdown 报告。

录音 08 | 下午三点/两点、否定与长中英混合段

恺撒渡河：决定之前与决定之后 - - 苏埃托尼乌斯《十二恺撒传》

时长 59.50 秒。Fun 最好，CER 4.51%；它保住了“我听成了两点”这一关键关系，其他三模型均出现“清晨”等同音错误。

模型	CER	英文 WER	处理 / 秒	汉字 CER	数字等值 CER
SenseVoice	7.99%	8.33%	1.45	9.33%	5.56%
Apple	14.58%	62.50%	2.09	12.44%	11.81%
Qwen3-ASR	4.86%	0.00%	9.99	7.25%	4.86%
Fun-ASR	4.51%	4.17%	9.00	5.70%	4.51%

参考原文（标题、正文、出处）

恺撒渡河：决定之前与决定之后 - - 苏埃托尼乌斯《十二恺撒传》
恺撒来到卢比孔河边时，知道带兵越过这条河意味着什么。在后人的叙述里，渡河常被看作果断的象征，但我更关心决定之前有没有认真讨论。We still have time to stop, but we may not have the same choice tomorrow. 今天发布一个消息、签下一份合同，也可能让很多人承担后果。如果同事说下午三点发布，我听成了两点，不能因为按钮已经按下，就说一切都是计划好的。A quick decision is not always a good decision. 果断值得欣赏，核对事实同样重要，尤其当承担代价的人，并不只是作出决定的那个人。
出处：《恺撒传》第三十一至三十三节。

各模型的关键差异

SenseVoice：“我听成了两点→我清晨了两点”，英文开头变为“with still have time stop”；中文数值用阿拉伯数字时严格 CER 另有格式罚分。

Apple Speech：“渡河→杜河”，英文多处连写和错拼；全条路由为 zh_CN。

Qwen3-ASR：两句英文一致；作者名“苏埃托尼乌斯”写成“衰托尼乌斯”，“我听成了两点”写成“我清晨的两点”。

Fun-ASR-MLT-Nano：保留“三点发布/听成两点”；漏掉英文“time to stop”中的 to，且“核对”写成“和对”。

共同偏差 / 复核：“恺撒→凯撒”是所有模型共有的同音字形偏差，严格 CER 计错，但应与三点/两点互换这类数值错误区分。

四模型完整原始转写与规范化逐字红绿差异，见配套 HTML 的对应录音章节；完整文字同时保存在 Markdown 报告。

录音 09 | 历史专名、rules/rulers 与跨语言保真

密洛斯对话：有力量是否就有道理 - - 修昔底德《伯罗奔尼撒战争史》

时长 70.33 秒。SenseVoice CER 最低，8.10%；Fun 的部分专名较好，但再次发生英文转中文。

模型	CER	英文 WER	处理 / 秒	汉字 CER	数字等值 CER
SenseVoice	8.10%	11.76%	1.62	10.23%	8.10%
Apple	11.84%	44.12%	2.47	6.25%	11.84%
Qwen3-ASR	9.03%	17.65%	11.03	8.52%	9.03%
Fun-ASR	13.71%	32.35%	8.46	9.66%	13.71%

参考原文（标题、正文、出处）

密洛斯对话：有力量是否就有道理 - - 修昔底德《伯罗奔尼撒战争史》
在修昔底德记述的密洛斯对话中，雅典使者强调力量，密洛斯人则希望保住自己的独立。The two sides were talking, but they were not asking the same question. 一方关心如何服从，另一方关心为什么必须服从。放到今天，一家大公司也可能告诉小商家：These are our rules. You can accept them or leave. 可如果离开就失去大部分收入，这样的选择究竟有多少自由？We need rules that protect people when they have less power. 历史让我警惕的，是把能够做到的事情，直接当成应该去做的事情，却不再解释理由。
出处：《伯罗奔尼撒战争史》第五卷：密洛斯对话。

各模型的关键差异

SenseVoice：“修昔底德→休息彼得”，专名严重失真；英文 rules 多处成为 rulers。

Apple Speech：英文出现“sidsmiltalking”“same crestin”“accept them early”等偏差；前后英文多位于 zh_CN 区间。

Qwen3-ASR：专名出现“修习己德/休斯底德”等错误，英文“The two sides were talking”改成“The two sides will talk”。

Fun-ASR-MLT-Nano：标题“修昔底德”正确；“but they were not asking the same question”变为“但它们不会问同一个问题”，破坏原语言保真。

共同偏差 / 复核：rules→rulers 是四模型共同出现的偏差，可能包含实际读音影响；当前评分只说明与参考不一致。纠错候选中本地模型还曾把大片英文转成中文，所幸被检查拒绝。

四模型完整原始转写与规范化逐字红绿差异，见配套 HTML 的对应录音章节；完整文字同时保存在 Markdown 报告。

录音 10 | 五十/四十/十先令、英文与自我修正

富兰克林办图书馆：个人努力与共同条件 - - 《富兰克林自传》

时长 63.40 秒。Qwen 最好，CER 3.83%；SenseVoice 在关键年费数值上出现明显参考不一致，需要人工复核。

模型	CER	英文 WER	处理 / 秒	汉字 CER	数字等值 CER
SenseVoice	6.71%	10.71%	1.43	9.79%	5.43%
Apple	13.10%	53.57%	2.21	10.82%	11.18%
Qwen3-ASR	3.83%	3.57%	9.60	5.67%	3.83%
Fun-ASR	6.07%	0.00%	8.48	9.28%	4.15%

参考原文（标题、正文、出处）

富兰克林办图书馆：个人努力与共同条件 - - 《富兰克林自传》
富兰克林在自传中写到，朋友们先把各自的书放在一起，后来又通过共同出资建立图书馆。起初参加的有五十个人，每人先交四十先令，以后每年再交十先令。One person could not buy every book, but together they could read much more. 这让我重新理解所谓自学：看起来是一个人在读书，背后却需要书籍、时间和可以安静坐下的地方。今天资料比过去丰富，有人仍然缺少这些条件。If we want more people to learn, we should make learning easier to reach. 与其只劝别人更加努力，不如也想想，我们能不能共同降低开始学习的门槛。
出处：《富兰克林自传》中的图书馆筹建记述。

各模型的关键差异

SenseVoice：“每年再交十先令”输出为“每年再交1现例”，将十写成 1；还出现“but让我”等语言衔接问题。默认模型的综合优势不代表金额无需核对。

Apple Speech：数值 50/40/10 基本保留，但“先令”不稳；45.47-52.14 秒被路由为 ko_KR，第二句英文严重失真。

Qwen3-ASR：保住五十、四十、十；“先令→先例”，“reach→each”。

Fun-ASR-MLT-Nano：50/40/10 的数值保留，英文词序列一致；“先令→先例”，“记述→技术”。

共同偏差 / 复核：“学习开开始学习”的重复被多模型共同保留，可能是实际朗读自我纠正。数字格式与数值错误分开看：50 与五十是格式差异，1 与十则不是。

四模型完整原始转写与规范化逐字红绿差异，见配套 HTML 的对应录音章节；完整文字同时保存在 Markdown 报告。

方法、审计与适用边界

参考稿采用用户本次提供的完整标题、正文及出处；用户明确确认三者均已朗读。“录音 1”等编号标签不计入。共 2,742 个规范化字符，其中汉字 1,744 个、英文 249 个单词。

每条录音仅取最新 batchID 内每个模型的最后一次运行，共 40 条主评结果。不回退挑选旧的成功结果。84 条历史运行单列用于稳定性审计，不混入主排名。

主指标 CER=(替换+删除+插入)/参考字符数。去掉标点和空白，仅折叠 ASCII 英文大小写；保留简繁、同音字及数字形式差异。Python 的 40 条 S/D/I、分母和 CER 均已与 App 实际 Swift Evaluation.cer 独立交叉校验。

端到端主排名将失败按空稿处理，CER=100%；这不同于 App 导出中失败 CER 留空的规则。成功样本 CER、共同成功的 9 条和失败率分别展示，避免隐藏不可用结果。

英文 WER 对提取出的英文词序列计算，保留模型的单词边界；中文 CER 对汉字序列计算。两者是分项诊断。MER 将每个汉字、英文词和独立数字串各计一单位，缓解混合 CER 对英文字符的较大权重。

数字等值 CER 仅把独立阿拉伯整数（小于 100）及 fifteen/fifty 转为相同中文数词。它是格式敏感性分析，不能掩盖 1 与十这类数值变化，也不替代严格 CER。

误差计数（最新批次，失败计空稿）

模型	替换 S	删除 D	插入 I	参考字符
SenseVoice	88	15	56	2742
Apple	142	358	57	2742
Qwen3-ASR	132	14	152	2742
Fun-ASR	93	57	49	2742

数据来源与版本

2026-10-29 10:11（北京时间）通过只读 USB HouseArrest 提取 10 个 Records JSON。手机硬件标识 iPhone18,1，iOS 27.2 / 24B119；读取时 App 0.5.3 / Build 11。未读取 API Key、未修改手机，也未重跑 ASR 或纠错。

录音 2、3、4 的 12 条主 ASR 运行来自 0.5.3 / Build 11；其余 28 条来自 0.4.1 / Build 10。模型版本一致，本地 Git 比较两版的 Engines / Audio / LanguageRouting 无差异；但保留此版本分层，不能把所有记录描述成一次全新的 0.5.3 测试。热状态均为 0，低电量模式均为 false。

原始 JSON、文件 SHA-256、每条运行与 batch ID、参考稿、CSV、分析脚本及 Swift 交叉验证程序都在配套数据包。主 CER 的 40 组 S/D/I、分母与分值已独立复核。

结论限于同一手机、同一说话人的 10 段约十分钟中英混读。未逐段审听原音，可能有读稿差异；未测多人、噪声、方言、长会议、实时流、手机峰值内存或功耗。